

סגמנטציית לקוחות תחת מבחן הזמן

האם סגמנט הוא תיאור יציב של הלקוח, או תצלום רגע של החלון שבו נמדד?

The logo for HIT, consisting of the letters 'HIT' in a stylized, bold, white font. The 'H' and 'I' are connected, and the 'T' is separate. The background is dark blue with a network of glowing blue dots and lines.

נדב פיירמן שטרן

99222 — למידת מכונה בלתי מפקחת

מרצה: ד"ר אורי איתי · HIT

הבעיה העסקית

חנות מתנות מקוונת בבריטניה. תקציב השיווק מוגבל, וצריך להחליט למי הוא הולך

2

שנות פעילות

75%

מן ההכנסה מגיעים מ-26% מן הלקוחות

50%

מן ההכנסה מגיעים מ-7% מן הלקוחות

- ▶ מיעוט קטן של לקוחות מייצר את רוב ההכנסה. השאלה היא מי הוא.
- ▶ פילוח הוא הכלי המקובל: מחלקים לקבוצות לפי התנהגות הקנייה.
- ▶ התנאי הסמוי: התקציב מוקצה חודשים מראש. סגמנט שמתחלף כל חודש לא שווה תקציב.

שאלת המחקר

מה שהמדדים המקובלים לא יכולים לענות עליו

האם סגמנט הוא תכונה של הלקוח, או רק תמונה של חלון הזמן שבו מדדנו אותו?

5

אלגוריתמים שנבדקו באותה שאלה

1,114

לקוחות שפעילים בשני חלונות

3

חלונות זמן רצופים

- ▶ אם מפצלים את הנתונים באקראי, אותו לקוח נופל משני צדי הגבול והשאלה מתרוקנת.
- ▶ לכן פיצלנו לפי זמן. לקוח שפעיל בשני חלונות מופיע בשניהם, ואפשר לבדוק אם קיבל את אותו סגמנט.
- ▶ המדדים המקובלים בודקים רק איך החלוקה נראית בתוך החלון שבו נלמדה — לא אם היא מחזיקה אחריו.

ארבעה מדדים — בשפה פשוטה

כל המצגת נשענת על ארבעת אלה, אז שווה שתי דקות עליהם

מדד הצורה — סילואט

כמה כל לקוח קרוב לקבוצה שלו, לעומת הקבוצה השכנה.
גבוה יותר — חלוקה נקייה יותר. נמדד רק בתוך החלון.

מדד ההסכמה

אותם לקוחות בשני מצבים: כמה זוגות שהיו יחד נשארו יחד.
 $1 =$ חלוקה זהה, $0 =$ כמו הגרלה. זה מדד היציבות בזמן.

הגברה מול מקרה

כמה יותר טוב מניחוש. 60 אחוז נשארו, ניחוש נותן 39 —
ההגברה 1.55 . בלי הבסיס, 60 אחוז לא אומר כלום.

דיוק מול בסיס

אותו רעיון במודל. הקבוצה הגדולה היא 47 אחוז,
אז מי שינחש רק אותה מגיע ל- 0.47 . הישג הוא מה שמעל.

הנתונים

Online Retail II ממאגר UCI · דצמבר 2009 עד דצמבר 2011

8

עמודות מקוריות

43

מדינות

5,942

לקוחות מזוהים

1.07M

שורות עסקה

- ▶ כל שורה היא פריט אחד בחשבונית אחת — לא לקוח ולא הזמנה. לכן יש הרבה יותר שורות מלקוחות.
- ▶ אין עמודת מטרה. זו הסיבה שהבעיה בלתי מפוקחת, ושאין תשובה נכונה להשוות אליה.
- ▶ איכות: **22.8** אחוז מן השורות בלי מזהה לקוח, **1.8** אחוז ביטולים, וקודי מוצר שאינם מוצרים.
- ▶ השורות בלי מזהה לקוח הוסרו — אי אפשר לצרף אותן ללקוח. הביטולים נשמרו, כי הם מקזזים הכנסה.
- ▶ בתיאור המערך כתוב שרבים מן הלקוחות הם סיטונאים. זו הנחה שנבדקה בהמשך והתאמתה.

המאמר שממנו יצאנו

Ozcan (2026) — מודל RFM מורחב לסגמנטציית לקוחות במסחר מקוון

מה המאמר מציע

RFM מודד שלושה דברים: מתי קנה, כמה פעמים, וכמה כסף.
המאמר מוסיף שלושה: עומק הסל, נתח ההנחות, וסדירות המרווחים.

מה הוא בודק

משווה שלושה אלגוריתמים, בוחר תשעה אשכולות, ומסיר חריגים לפי כלל סטטיסטי.

למה זה לא שחזור


הנתונים והקוד של המאמר אינם ציבוריים.
לכן זה מבחן העברה, לא שחזור.

- ▶ השאלה שנבדקת: האם המסגרת עובדת גם על מערך נתונים שלא נבנה עבורה.
- ▶ ומה קורה לרכיבים שלה כשהשדות שהם נשענים עליהם פשוט לא קיימים בנתונים החדשים.


מהנתונים הגולמיים ללקוחות

שני צעדים שקובעים את כל מה שבא אחריהם: איך מפצלים בזמן, ואיך מצרפים ללקוח

The temporal split: three consecutive windows, cut at midnight



From rows to customers, inside the training window (60% of the data)




▶ משמאל הפיצול: 60/20/20, חיתוך בחצות. כל מה שנלמד — מחלון האימון בלבד.

▶ מימין האגרגציה: מיליון שורות הופכות ל-3,057 לקוחות עם שתי חשבוניות לפחות.

הבעיה: כל הלקוחות נדחסים לפינה אחת

רוב הלקוחות קטנים ומעטים ענקיים — ובלי טיפול, הענקיים קובעים הכל



‣ למעלה לפני: כמעט כל הלקוחות יושבים בעמודה אחת בקצה, והשאר נמרח על כל הציר.


‣ למטה אחרי: אותם נתונים בדיוק, פרושים. מספר העיוות ליד כל כותרת יורד כמעט לאפס.

הפתרון: Yeo-Johnson ואז מתיחה

נוסחה אחת שמיישרת כל מאפיין בנפרד, ואז מותחת את כולם לאותו טווח

$$\psi_\lambda(y) = \begin{cases} \frac{(y+1)^\lambda - 1}{\lambda} & \lambda \neq 0, y \geq 0 \\ \ln(y+1) & \lambda = 0, y \geq 0 \\ -\frac{[(1-y)^{2-\lambda} - 1]}{2-\lambda} & \lambda \neq 2, y < 0 \\ -\ln(1-y) & \lambda = 2, y < 0 \end{cases}$$

$$x' = \frac{\psi_\lambda(y) - \psi_{\min}}{\psi_{\max} - \psi_{\min}} \in [0, 1]$$





▶ הנוסחה מוצאת לכל מאפיין חזקה משלו. לוגריתם היה נכשל כאן, כי יש בנתונים החזרות.

▶ התוצאה: הקופסאות נפתחות, והעיוות יורד מ-5.26 במוצע ל-0.20.

▶ ולא הסרנו חריגים: הכלל שהמאמר מציע היה מוחק כשליש מהלקוחות. זה לא ניקוי, זו החלטה מי נחשב לקוח.

ניקוי מאפיינים כפולים

מתאם ספירמן בערך מוחלט — הוא תופס יחס מונוטוני, וכפילות היא בדיוק זה



- מימין לפני: יש זוגות שהם אותו משתנה פעמיים. תדירות היא מספר החשבוניות חלקי אורך החלון — מתאם **1.00**.
- משמאל אחרי: מתוך תשעת הנבחרים נשאר זוג אחד קשור, ואותו שמרנו במכוון כי המאמר מבקש את שניהם.

האלגוריתמים — מה כל אחד עושה

חמישה שמחלקים את כל הלקוחות, ואחד שבודק אם בכלל יש מה לחלק

K-Means · מחלק לפי מרחק ממרכז. כל אשכול מיוצג בממוצע שלו, וכל לקוח הולך למרכז הקרוב אליו.

K-Medoids · אותו דבר, אבל המרכז חייב להיות לקוח אמיתי מהנתונים. פחות רגיש לחריגים.

Fuzzy C-Means · לא מחליט חד. כל לקוח מקבל אחוז שייכות לכל אשכול, והתווית היא הגבוה שבהם.

Agglomerative · מתחיל מכל לקוח לחוד ומחבר בכל צעד את שני הקרובים, עד שנשאר המספר שביקשנו.


Gaussian Mixture · מניח שהנתונים הם ערבוב של כמה התפלגויות פעמון, ומחשב לכל לקוח הסתברות לכל אחת.

HDBSCAN · שונה מכולם: לא מקבל מספר אשכולות. מחפש אזורים צפופים, ומה שלא צפוף מסומן כרעש.

► החמישה הראשונים עוברים אותו מסלול. HDBSCAN הוא בקרה: הוא לא מצא אף אזור צפוף של **100** לקוחות מתוך **3,057** — כלומר אין כאן גבולות טבעיים.

אילו מאפיינים נכנסים

כמה מן ההבדל בין הלקוחות כל מאפיין מסביר — לפי הקיבוץ עצמו



‣ המדד פשוט: עד כמה ההשתייכות לאשכול מסבירה את הערך של אותו מאפיין.



‣ שני המובילים — סדירות ותדירות — יצאו זהים בכל חמשת האלגוריתמים.

‣ לקחנו תשעה. זה המספר הקטן ביותר שכולל את שלושת מדדי RFM.

‣ מה שמעבר לתשעה יושב בתחתית הדירוג וכמעט לא משפיע.

כמה מאפיינים, וכמה אשכולות

שתי החלטות — ובשתיהן הכלים המקובלים לא נותנים תשובה אחת





‣ משמאל, כמה מאפיינים: הכתום הוא איכות החלוקה והוא יורד עם כל מאפיין נוסף. הירוק הוא היציבות, והוא כמעט שטוח.

‣ מימין, כמה אשכולות: SSE יורד חלק בלי מרפק, והסילואט מגיע לשיא דווקא ב- $k=2$ — הערך הקטן ביותר האפשרי.

‣ שני הגרפים אומרים אותו דבר: הנתונים לא מתייבים מספר. לכן הכרענו לפי יציבות — תשעה מאפיינים ושלושה אשכולות.

K-Means: האלגוריתם שנבחר

שני מבחנים — האם הסגמנט מכיל ללקוחות חדשים, והאם הוא מחזיק בחלון הבא




- ▶ משמאל ההכללה: K-Means ראשון עם **0.928** מול בסיס **0.467**. Fuzzy C-Means שני ב-**0.914**, אך ה-macro-F1 שלו **0.743** בלבד.
- ▶ לכל אלגוריתם בסיס משלו, והמרווח מוטה לטובת K גדול. הכרענו לפי היציבות שמימין: K-Means מוביל, Fuzzy C-Means אחרון.
- ▶ מכאן והלאה הכל על הפילוח שלו.

בדיקה: אפשר בכלל לנחש את הסגמנט?

המסווג רץ ברמת הלקוח — שורה אחת לכל לקוח, לא לכל מוצר ולא לכל שורת עסקה

The classifier across all three windows

one row per customer · 3,057 train · 1,511 validation · 1,398 test



▶ האפור הוא חלון האימון: **1.000** בכל מדד, וזה מובן מאליו — שם נוצרו התוויות.

▶ עמודות המבחן הן חלק מאותה קריאה יחידה של חלון המבחן, שמוצגת במלואה בהמשך.


▶ הירוק הוא הוולידציה, **0.928**. הכהה הוא המבחן, **0.866**. ירידה מתונה על פני שמונה חודשים.

▶ העמודה האחרונה היא הרף בכל חלון. המודל כמעט מכפיל אותו בשלושתם.

▶ ו-macro-F1 צמוד לדיוק תמיד — כלומר הצלחנו גם על שני הסגמנטים הקטנים.

שלושת הסגמנטים

תשעה מאפיינים, שלושה אשכולות — וכך הם נראים בשני הכיוונים העיקריים



סיטונאי-מבצעים

684 לקוחות · 58% מן ההכנסה

לכאן רוב תקציב השימור.

קמעונאי סדיר

1,251 לקוחות · 32% מן ההכנסה · סל קטן, קצב קבוע

לא לגעת במחיר. להגדיל את הסל.


קונה מזדמן

1,122 לקוחות · 9% מן ההכנסה · רק 16% חוזרים

לא להשקיע בשימור.

ומה זה נראה בעין


כל זוג מאפיינים זה מול זה — הצבע הוא הסגמנט



- ▶ הכתום נפרד בקו חד: אצלו הסדירות והחזרתיות הן אפס, כי הוא קנה רק פעמיים.
- ▶ הכחול והירוק נפרדים כמעט רק על נתח ההנחות, ובמידה קטנה על הקניות בכמויות.
- ▶ כלומר שלושה סגמנטים, אבל בפועל שתי החלטות בלבד.

מה דוחף לקוח לסגמנט הסיטונאי


לקחנו כל תחזית ופירקנו אותה: כמה כל מאפיין תרם, ולאיזה כיוון



- ▶ כל נקודה היא לקוח. ימינה פירושו נדחף פנימה, שמאלה נדחף החוצה, והצבע הוא ערך המאפיין.
- ▶ נתח ההנחות ראשון, וסדירות המרווחים אחריו. יחד הם כמחצית מכל ההשפעה.
- ▶ ומדדי RFM הקלאסיים בתחתית: הכסף שביעי, והזמן מאז הקנייה האחרונה שמיני.
- ▶ המסקנה: דווקא התוספות שהמאמר הציע הן שעושות את העבודה.

הממצא המרכזי

השווינו שתי הסכמות — וההפרש ביניהן הוא התשובה



מה השווינו



ימין: חמישה אלגוריתמים, אותו חלון. כמה הם מסכימים.
שמאל: אותו אלגוריתם, חלון אחר. כמה הוא מסכים עם עצמו.

מה יצא

0.41 מול **0.08**. פי חמישה.
הגבול הוא של החלון, לא של הלקוח.

חלון המבחן

קריאה אחת בלבד, לתצורה הנבחרת — ואחריה לא שינינו אף החלטה



► משמאל: צורת החלוקה נחלשת אבל לא קורסת. ההסכמה על הלקוח הבודד מתחת ל-0.17.

► מימין: ובכל זאת כל שלושת הסגמנטים נשארים מעל המקרה, והסיטואי הכי חזק — פי 2.41 מהצפוי.

מה זה שווה לעסק

התוויות האישיות לא שורדות — אבל הכסף כן

Revenue share by segment, test window

tile area is revenue share

segment 0
rev 33.9%
cust 34.0%

segment 2
rev 48.9%
cust 23.5%

segment 1
rev 17.3%
cust 42.5%

כן — תקצוב ברמת קבוצה

רבע מן הלקוחות, כמעט מחצית מן ההכנסה — גם בחלון המבחן.
על זה אפשר לבנות תקציב ולתכנן מלאי.

לא — פנייה אישית לפי תווית

התווית של לקוח בודד מתחלפת. מסע אוטומטי ירוץ על תווית ישנה.
לפנייה אישית צריך מודל אחר.

► עלות הטעות אסימטרית: פנייה מיותרת מבזבזת תקציב, פספוס סיטונאי עולה כפול.

► שיפור מדיד דורש קמפיין עם קבוצת ביקורת — וכזה אין בנתונים.

מה עבר מן המאמר ומה לא

זו הייתה השאלה מלכתחילה: האם המסגרת עובדת על נתונים אחרים

עבר

בחירת האלגוריתם. גם כאן K-Means יוצא הכי טוב, בדיוק כמו במאמר — אבל על נתונים אחרים לגמרי.

לא עבר

מספר האשכולות. המאמר בוחר תשעה. כאן שום חלוקה מעל חמישה לא שורדת את המעבר לחלון הבא.

נשבר

הסרת החריגים הייתה מוחקת כשליש מהלקוחות. ונתח ההנחות מודד בפועל מחיר סיטונאי, כי אין בנתונים סימון של קמפיין.

► מסגרת עוברת היכן שהיא אלגוריתמית, ונשברת היכן שהיא תלוית שדות.

מה אי אפשר לטעון מכאן

המגבלות של העבודה, בשפה פשוטה

- ▶ נתח ההנחות הוא ניחוש. סימנו שורה כהנחה אם המחיר נמוך מהרגיל — אבל אין בנתונים שדה שאומר "זה קמפיין". בפועל זה מודד מחיר סיטונאי, וזה דווקא המאפיין הכי חשוב בפילוח.
- ▶ קטגוריות המוצרים נבנו ממילות מפתח בתיאור החופשי. **13.2** אחוז מן השורות לא התאימו לשום קטגוריה.
- ▶ סף היציבות שבחרנו הוא החלטה שלנו, לא משהו שנגזר מהנתונים. סף אחר היה נותן רשימת תצורות אחרת.
- ▶ הנתונים הם ענן רציף בלי גבולות טבעיים. החלוקה שימושית, אבל היא נכפית ולא מתגלה.
- ▶ חנות אחת, בריטית ברובה, שנתיים. אין כאן טענה על ענפים אחרים או תקופות אחרות.

מה הלאה, ומה למדתי

שני דברים שהייתי עושה אחרת, ושלושה שהייתי מוסיף

מה הייתי מוסיף

סימון קמפיין אמיתי במקום הניחוש, ואז לבדוק שוב מי המאפיין הכי חשוב.
 ניטור בייצור: האיכות ירדה מ-0.208 ל-0.157 בשמונה חודשים. צריך אימון
 מחדש חודשי והתרעה כשזה צונח.
 לוותר על חלוקה מלאה: לזהות גרעין צפוף ולהשאיר את השאר בלי תווית — זה
 תיאור כן יותר של הנתונים.
 להשתמש באחוזי השייכות של Fuzzy C-Means כמשקל, במקום בתווית חד-
 משמעית.

מה למדתי

המדדים שבחרים את מספר האשכולות מוטים, וכל אחד לכיוון אחר. גיליתי את
 זה רק אחרי שכבר בניתי את הסריקה.
 הממצא המרכזי לא היה השאלה שאיתה התחלתי. הוא צץ בדרך.
 אם הייתי מתחיל מחדש, הייתי מודד יציבות בזמן כבר בהתחלה — ולא בסוף
 כמסן.

פילוח לקוחות שווה תקציב רק אם הוא שורד את החודש הבא.

שאלות